Analisis Text

(Akmal Setiawan Wijaya), (Faishal Basbeth)

(20917005), (20917015)

- 1. Pada percobaan ini, di gunakanlah corpus tentang berita berita, berita ini menggunakan Bahasa Inggris.
- 2. Proses pembuatan *Topic Modeling*, ada beberapa tahap, tahap yang pertama pastinya dibutuhkannya sebuah *library* yang akan digunakan pada percobaan ini, setelah itu import data tersebut ke dalam sistem yang digunakan untuk membuat model tersebut, disini digunakanlah *Jupyter*, lalu dilakukanlah *preprocessing* data, contoh pada *preprocesing* disini adalah pemberian token pada masing masing kata. Lakukanlah Penentuan *Bow* dari dataset tersebut, setelah itu dilakukan proses TF-IDF, dan lakukanlah *training* model, lebih jelasnya bisa dilihat pada Gambar 1 7.
 - Topic Modeling

```
In [1]: W
    import pandas as pd
    import gensim
    from nltk.stem import WordNetLemmatizer, SnowballStemmer
    from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer, HashingVectorizer
    from sklearn.decomposition import PCA
    import matplotlib.pyplot as plt
    import seaborn as sns
    from nltk.stem.porter import *
    import numpy as np
    np.random.seed(2018)
    import re
    from sklearn.cluster import KMeans
```

Gambar 1. Import library yang dibutuhkan

```
In [3]: W # Load Data
data = pd.read_csv('abcnews-date-text.csv', error_bad_lines=False);
data_text = data[['headline_text']]
data_text['index'] = data_text.index
documents = data_text
```

Gambar 2. Import data dari csv

Gambar 3. Preprocesing data

Gambar 4. Menentukan Bow dari dataset

Gambar 5. mencari TF-IDF

Gambar 6. Proses Training

Gambar 7. Hasil topic modeling

Pada gambar 7 dapat dilihat hasil dari topic modeling. Pada *topic* pertama dapat dilihat hasil nya polisi, duggaan, kematian, case, pembunuhan. Kemudan pada topic kedua dapat dilihat hasilnya pulau, australia, berita, pasar, dunia

3. Pada proses *Clustering* ini, seperti deskripsinya clustering adalah sebuah proses pengelompokan data dimana data tersebut tidak memiliki label, dari deskripsi yang di dapat, *Clustering* ini melakukan proses beberapa tahap yaitu seperti biasa di butuhkanlah *Import* masing – masing *library* yang di gunakan, dan juga upload data yang digunakan / yang akan di kelola, dan juga lakukanlah *preprocesing* data, perbedaan disini, disini ada proses perhitungan *vectorizer* daripada proses *Topic Modeling* di atas, lakukanlah *training*, dan *training* tersebut digunakanlah dengan algoritma *k-Means*, setelah itu didapatkanlah *plot clusternya*.

- Clustering

```
In [1]: N import pandas as pd
import gensim
from nltk.stem import WordNetLemmatizer, SnowballStemmer
from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer, HashingVectorizer
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
import seaborn as sns
from nltk.stem.porter import *
import numpy as np
np.random.seed(2018)
import re
from sklearn.cluster import KMeans
```

Gambar 8. Import Library yang dibutuhkan

```
In [5]: M # read data
data = pd.read_csv('bbc-text.csv');
```

Gambar 9. Load data

```
In [3]: # lemmatize dan stem preprocessing
stemmer = SnowballStemmer(language='english',ignore_stopwords=True)
def lemmatize_stemming(text):
    return stemmer.stem(WordNetLemmatizer().lemmatize(text, pos='v'))
def preprocess(text):
    result = []
    for token in gensim.utils.simple_preprocess(text):
        if token not in gensim.parsing.preprocessing.STOPWORDS and len(token) > 3:
            result.append(lemmatize_stemming(token))
        return ' '.join(result)

In [4]: # Preprocess headLine text dan simpan ke 'processed_docs'
processed_docs = data['text'].map(preprocess)
processed_docs.head(10)

Out[4]: 0 futur hand viewer home theatr system plasma hi...
```

Gambar 10. Preprocessing data

```
In [5]: # # menghitung Vectors sebagai fitur
# membuat dan menghitung vectorizer object
count_vect = CountVectorizer(analyzer='word', token_pattern=r'\w{1,}')
count_vect.fit(processed_docs)
# transform training dan validation data menggunakan vectorizer object
count_vec = count_vect.transform(processed_docs)
```


Gambar 11. menghitung vectorizer

```
In [6]: W # parameter cluster K =3
    final_model=KMeans(3)
    final_model.fit(count_vec)
    prediction=final_model.predict(count_vec)
```

Gambar 12. Training dengan Kmeans

Gambar 13. Plot data cluster

Dari plot pada gambar 13 dapat disimpulkan pada *cluster* 3 memiliki jumlah data paling banyak sebesar 1600.



Gambar 14. Hasil output dari masing masing cluster

Dari gambar 14 dapat dilihat hasil dari masing masing *cluster*. Pada *cluster* pertama masuk ke katagori politik dan entertaiment. Kemudian pada *cluster* kedua ada katagori teknologi dan politik. Pada kluster terakhir terdapat 3 campuran katagori bisnis, olahraga dan politik.